

Dados e IA no Brasil: Evidências para a Expansão de uma Instituição Financeira

Diretrizes de Mercado para Contratação, Remuneração, Capacitação, Retenção e Governança de IA com base na série histórica State of Data Brasil (2023–2026)

Caso da Instituição Financeira

Suporte a decisões executivas de atração de talentos, remuneração, formação técnica, políticas de trabalho e investimentos em IA.

Arquitetura Medallion AWS

Pipeline em 3 camadas no Amazon S3 (Bronze, Silver, Gold), processamento distribuído com PySpark no AWS Glue e consultas no Amazon Athena.

Base Consolidada

14.002 registros históricos (5.293 em 2023–24, 5.215 em 2024–25 e 3.494 em 2025–26) auditados sob rigorosos critérios de integridade estatística.

Três Decisões Centrais que o Estudo Orienta

- 1. **Estratégia de Atração e Remuneração de Talentos:** Calibrar contratações para perfis de alta complexidade (Engenharia e IA) sem inflacionar a folha global, explorando contratação distribuída como hipótese a testar.
- 2. **Investimento Tecnológico e Capacitação Interna:** Definir uma stack tecnológica interoperável e desenhar trilhas de upskilling focadas em competências fundamentais transferíveis (SQL, Python, Cloud e Modelagem).
- 3. **Transição de IA Experimental para Pilotos Governados:** Superar o estágio de licenças isoladas e criar um modelo corporativo de GenAI com segurança de dados sensíveis (LGPD/Sigilo Bancário) e ROI mensurável.

Foco Executivo: Transformar dados empíricos de mercado em escolhas estratégicas defensáveis para a diretoria do banco.

Tese Central do Diagnóstico de Mercado

O QUE O MERCADO REVELA

A remuneração nominal média estimada avançou +26,4% no período analisado e cresceu o financiamento empresarial de ferramentas de IA (de 6,4% para 42,3%). Persistem concentração no Sudeste (>60%), baixa participação feminina (22,0%) e disparidade de satisfação em modelos presenciais.

INTERPRETAÇÃO PARA O SETOR FINANCEIRO

O mercado brasileiro de dados amadureceu em custos e expectativas, mas opera com funis de contratação restritos e riscos de dispersão de orçamento em IA sem governança.

DIRETRIZ ESTRATÉGICA PARA O BANCO

Combinar contratação sênior cirúrgica, formação técnica interna de plenos, pilotos de contratação regional distribuída com flexibilidade de trabalho e pilotos governados de IA com validação de retorno.

Composição Amostral por Edição da Pesquisa

5.293

2023–2024

0 dups removidas

5.215

2024–2025

2 dups removidas

3.494

2025–2026


1 dup removida

Etapas de Auditoria	Regra Aplicada	Status
Deduplicação de Chave	Chave (ano, id) com hash SHA-256 para nulos	Totalmente Auditado
Estimativa Salarial	Ponto médio em faixas fechadas; 1.2x no topo aberto	Métrica Contínua
Compleitude Crítica	Gênero (100%), Região (97,2%), Salário (91,7%)	Acima dos Limites
Taxa de Satisfação	Denominador estrito sobre respostas válidas	Sem Distorção

Limitações e Ressalvas Metodológicas Essenciais

- Amostra Voluntária de Conveniência:** A pesquisa não constitui um censo populacional nem um painel longitudinal (não acompanha os mesmos indivíduos ano a ano).
- Variação Volumétrica em 2025–2026:** A redução de ~33% no volume de respondentes reflete dinâmicas de engajamento da coleta, e não retração do mercado de trabalho de dados.
- Salários Estimados Nominais:** Os valores salariais são aproximações baseadas em faixas textuais brutas sem correção inflacionária pelo IPCA.
- Faixa Inconsistente Preservada:** Uma inconsistência de digitação na fonte de 2025–2026 foi mantida por integridade (impacto de R\$ 0,21 na média geral).

Critério Analítico: Variações temporais indicam mudanças na composição da amostra participante, devendo ser interpretadas com cautela estatística.



Arquitetura da Plataforma de Dados — Data Lakehouse em 3 Camadas Medallion no Amazon S3 com AWS Glue, PySpark e Amazon Athena



Destaques Técnicos da Solução AWS

- **Amazon S3 Data Lake (3 Camadas):**
 - *Bronze*: CSVs brutos originais preservados.
 - *Silver*: Parquet + Snappy particionado por ano, tipos inferidos e deduplicado.
 - *Gold*: 7 Data Marts agregados com contadores ponderados.
- **AWS Glue Jobs (PySpark):**
 - tc3-bronze-to-silver: Leitura com fail-fast, multiline e padronização.
 - tc3-silver-to-gold: Explode de tecnologias e percentis aproximados.
- **AWS Glue Data Catalog & Athena:** Database centralizado db_state_of_data para consultas interativas SQL de alta performance e baixo custo.
- **Auditoria Local de BI/Cloud (Por que foi necessária?):**

A fonte bruta de 2025–2026 continha sobreposição de categorias (a coluna binária de Looker incluía indevidamente 206 seleções de Looker Studio). Para preservar o Data Lake na AWS sem corromper o schema estável da Gold, executou-se essa auditoria e parsing textual local antes de evoluir o schema oficial no Glue.

Mercado de dados em cinco indicadores

Última edição e variação acumulada no período

Participação feminina	Concentração no Sudeste	Satisfação no trabalho	Trabalho 100% remoto	Média salarial estimada
21,9%	62,1%	69,0%	36,7%	R\$ 13.329
2025-2026	2025-2026	2025-2026	2025-2026	2025-2026
-2.5 p.p. vs. 2023-2024	+2.2 p.p. vs. 2023-2024	-3.0 p.p. vs. 2023-2024	-4.9 p.p. vs. 2023-2024	+26.4% vs. 2023-2024

Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

A remuneração nominal média estimada cresceu +26,42% (de R\$ 10.543,75 para R\$ 13.329,00). A concentração no Sudeste subiu +2,16 p.p. (62,11%), enquanto a representatividade feminina caiu -2,48 p.p. (21,95%) e o trabalho 100% remoto recuou -4,92 p.p. (36,66%). A satisfação válida recuou -2,97 p.p. (68,98%).

2. INTERPRETAÇÃO ESTRATÉGICA


O mercado reflete uma dinâmica de encarecimento nominal da mão de obra, aumento da centralização geográfica e sinais de atrito com políticas corporativas de retorno presencial.

3. IMPLICAÇÃO PARA O BANCO

O banco não deve competir exclusivamente por salário no Sudeste; deve utilizar flexibilidade de trabalho e programas internos de formação como alavancas de eficiência.

Distribuição regional dos profissionais

Participação no total de respondentes de cada edição



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

O Sudeste concentra 62,11% dos respondentes na última edição (2025–2026), seguido por Sul (18,43%), Nordeste (10,48%), Centro-Oeste (6,55%) e Norte (1,92%). A concentração no Sudeste manteve-se superior a 60% em todas as três edições analisadas.

2. INTERPRETAÇÃO ESTRATÉGICA

A centralização no Sudeste gera forte concorrência por talentos locais entre bancos e fintechs. Contudo, 62% no Sudeste não comprova, isoladamente, a pronta disponibilidade de profissionais em outras regiões.

3. IMPLICAÇÃO PARA O BANCO

Oportunidade a testar: Estruturar um piloto controlado de contratação regional distribuída nos polos do Sul (PR/SC/RS), Nordeste (PE/CE/BA) e Centro-Oeste para avaliar custo de atração, tempo de fechamento de vagas e engajamento antes de expandir a operação.



1. EVIDÊNCIA DOS DADOS

Filtro com mínimo de 30 salários válidos por corte. Sêniores em Engenharia de Dados (R\$ 17.689,45), Ciência de Dados (R\$ 16.920,40) e Analytics Engineering (R\$ 15.650,30) lideram entre funções individuais, enquanto posições especializadas e de liderança técnica superam R\$ 20 mil. A progressão de Júnior para Sênior varia de 2,3x a 2,5x.



2. INTERPRETAÇÃO ESTRATÉGICA

O mercado paga prêmio elevado pela capacidade de construir pipelines escaláveis e sustentar modelos em produção. Funções de BI e análise básica apresentam faixas mais acessíveis (R\$ 4.500 a R\$ 8.500).

3. IMPLICAÇÃO PARA O BANCO

Não tomar o topo do mercado como parâmetro para toda a equipe. Contratar especialistas e arquitetos cirurgicamente, focando na promoção e formação interna de plenos.

Utilização Tecnológica no Cotidiano dos Profissionais de Dados (2025–2026)
Complemento Analítico Local: Uso Efetivo vs Preferência Declarada



Fonte: State of Data Brasil 2025–2026 (Data Hackers & Bain). Análise complementar local das questões 4.g e 4.e. Não calculado no Athena.

1. EVIDÊNCIA DOS DADOS

Na edição 2025–2026 (questões multiseleção 4.g e 4.e): Power BI é usado no dia a dia por 59,00% (1.242/2.105), Looker Studio por 15,58% (328/2.105), Tableau por 13,63% (287/2.105) e Looker por 12,78% (269/2.105). Em Cloud: AWS lidera com 48,26% (1.011/2.095), Azure tem 34,84% (730/2.095) e Google Cloud 30,88% (647/2.095).

2. INTERPRETAÇÃO ESTRATÉGICA


O ecossistema corporativo é predominantemente multicloud e híbrido. Power BI e AWS são os líderes de execução diária, mas há forte presença combinada de Azure e GCP.

3. IMPLICAÇÃO PARA O BANCO

Garantir arquitetura corporativa interoperável e governança centralizada, sem impor migrações monolíticas desnecessárias. Capacitar equipes em fundamentos multicloud.

Tecnologias com maior adoção em 2025-2026

Top 5 por categoria; linguagens permitem múltiplas respostas



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

Em preferências técnicas declaradas: Python (92,07%) e SQL (84,19%) são as linguagens hegemônicas absolutas (n=2.094 válidas em 2025–2026). Em preferência de BI: Power BI (50,51%) e Tableau (17,45%). Em preferência de Cloud: AWS (31,74%), GCP (22,55%) e Azure (20,13%).

2. INTERPRETAÇÃO ESTRATÉGICA


SQL e Python são as competências universais de maior liquidez e transferibilidade entre equipes de Engenharia, Analytics e Data Science.

3. IMPLICAÇÃO PARA O BANCO

Estruturar trilhas internas de upskilling baseadas em SQL avançado (modelagem dimensional), Python para automação/análise e governança de dados na nuvem, reduzindo dependência de contratações externas caras.


Participação feminina

Percentual sobre todos os respondentes



Diferença salarial de gênero

Quanto a média feminina está abaixo da média masculina



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

A participação feminina recuou para 21,95% na amostra de 2025–2026 (contra 24,43% em 2023–2024). A diferença salarial média bruta declarada é de ~19,4% (Homens: R\$ 13.944,95 vs Mulheres: R\$ 11.238,40).

2. INTERPRETAÇÃO ESTRATÉGICA

A disparidade agregada reflete majoritariamente o efeito de funil (pipeline), com menor presença feminina em cargos seniores de engenharia e arquitetura.


3. IMPLICAÇÃO PARA O BANCO

Implementar metas afirmativas na contratação inicial e programas internos de mentoria e aceleração para posições de liderança técnica.

Ressalva Metodológica Crítica: A diferença salarial média observada (~19,4%) é *bruta e não controlada* por cargo, senioridade, região ou tempo de experiência. Ela reflete a assimetria na composição dos grupos e não deve ser interpretada como remuneração diferente para trabalho de igual valor.


Distribuição dos modelos

Participação em 2025–2026



Satisfação por modelo

Sobre respostas válidas em 2025–2026



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

Em 2025–2026 (respostas válidas): modelos 100% Remoto (74,80%) e Híbrido Flexível (72,40%) apresentam taxas de satisfação declarada superiores ao 100% Presencial (52,10%) — uma diferença de mais de 20 pontos percentuais.

2. INTERPRETAÇÃO ESTRATÉGICA


Políticas presenciais rígidas associam-se a risco de perda e menor satisfação dos profissionais em áreas técnicas concorridas.

3. IMPLICAÇÃO PARA O BANCO

Hipótese de retenção a testar: Priorizar modelos híbridos flexíveis como padrão, estabelecendo a frequência presencial ideal através de piloto interno acompanhado de métricas de retenção, engajamento e entregas técnicas.

Prioridade de IA nas empresas

Distribuição entre respondentes válidos da pergunta



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

Entre os gestores respondentes (n=652 em 2025–2026), 60,58% declaram que IA é uma das principais prioridades (39,42% prioridade relevante, 21,16% principal prioridade da empresa), saltando de 36,16% em 2023–2024.

2. INTERPRETAÇÃO ESTRATÉGICA


Ressalva: O indicador mede a percepção dos gestores participantes, não um censo de empresas jurídicas. Ele reflete forte pressão executiva por adoção e alocação de orçamento.

3. IMPLICAÇÃO PARA O BANCO

Canalizar o apetite executivo para casos de uso estruturantes (ex: concessão de crédito, detecção de fraude, automação de compliance), evitando dispersão em iniciativas sem metas de retorno.

Uso pessoal de soluções de IA

Pergunta multiseleção; percentuais não precisam somar 100%



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

Entre não gestores (n=2.105 em 2025–2026): 42,33% utilizam ferramentas de IA pagas pela empresa (contra 6,36% em 2023–2024). 29,83% usam ferramentas de IA voltadas para código/programação.

2. INTERPRETAÇÃO ESTRATÉGICA

O financiamento corporativo comprova compra institucional de licenças (ex: Copilot, ChatGPT Enterprise), mas não atesta governança de dados sensíveis nem mensuração de produtividade real.

3. IMPLICAÇÃO PARA O BANCO

Criar um ambiente corporativo protegido (sandbox seguro com mascaramento de dados) e medir ganho de produtividade em pilotos controlados de desenvolvimento de software e análise.

Pilar Estratégico	Evidência dos Dados	Risco ou Oportunidade	Decisão Proposta	Indicador de Validação
1. Contratação	Perfis especializados e de liderança técnica superam R\$ 20 mil; concentração de 62% no Sudeste.	Disputa predatória inflaciona custos locais e alonga o fechamento de vagas.	Contratar sêniores cirurgicamente e testar piloto de contratação regional distribuída fora do Sudeste.	Tempo de fechamento de vagas e custo médio de atração.
2. Capacitação	Python (92%) e SQL (84%) lideram com folga as preferências de linguagens.	Treinamentos dispersos em ferramentas de nicho geram baixo retorno.	Criar academia interna de dados focada em SQL avançado, Python e arquitetura cloud.	Taxa de conclusão de trilhas e promoção interna de Plenos.
3. Retenção	Modelos flexíveis superam o presencial em mais de 20 p.p. na satisfação declarada.	Imposição 100% presencial arrisca aumento de turnover voluntário e menor satisfação dos profissionais.	Priorizar modelos híbridos flexíveis, definindo a frequência presencial através de piloto interno.	Turnover voluntário e eNPS (satisfação do colaborador).
4. Diversidade	Participação feminina de 22,0% e diferença salarial média bruta de 19,4% (não controlada).	Homogeneidade limita inovação e prejudica a imagem institucional.	Metas de recrutamento afirmativo e aceleração de lideranças técnicas femininas.	% de mulheres em vagas sênior e paridade em cargos iguais.
5. Inteligência Artificial	42,3% usam IA paga pela empresa; 60,6% dos gestores veem IA como prioridade.	Dispersão de capital e riscos de segurança de dados bancários (LGPD).	Implantar sandbox corporativo seguro e homologar 3 casos de uso de crédito/fraude.	Ganho de tempo medido e ROI financeiro dos pilotos.

0 a 30 Dias: Diagnóstico & Alinhamento

- **Mapeamento de Competências:** Levantar inventário interno de proficiência em SQL, Python, Cloud e Modelagem.
- **Desenho do Piloto Regional:** Mapear vagas abertas e desenhar teste de atração remota no Sul e Nordeste.
- **Seleção de Casos de Uso de IA:** Selecionar 2 a 3 pilotos de GenAI (ex: esteira de crédito e copiloto de código).

Entrega: Matriz de gaps técnicos e termo de abertura dos pilotos de IA.

31 a 60 Dias: Estruturação & Pilotos

- **Lançamento da Academia de Dados:** Iniciar trilhas internas de SQL e Engenharia de Dados na AWS.
- **Sandbox Seguro de GenAI:** Homologar ambiente protegido com mascaramento de dados (LGPD e sigilo bancário).
- **Piloto de Modelo Híbrido:** Testar política flexível, acompanhando métricas de retenção antes de fixar dias específicos.

Entrega: Pilotos de IA em execução e 1ª turma de capacitação iniciada.

61 a 90 Dias: Mensuração & Escala

- **Avaliação de ROI dos Pilotos de IA:** Medir ganho de produtividade e acurácia dos modelos frente ao baseline.
- **Auditoria de Equidade Salarial:** Concluir verificação de paridade salarial de gênero para cargos iguais.
- **Avaliação do Piloto Regional:** Medir tempo de fechamento de vagas, aderência técnica e custo de atração no Sul e Nordeste.

Entrega: Relatório executivo de ROI dos pilotos e plano de escala para 12 meses.

1. Capacidades Críticas & Engenharia

Contratar sêniores cirurgicamente para arquitetura e liderança de dados, enquanto capacita a base interna em SQL avançado e Python.

MÉTRICA DE ACOMPANHAMENTO

Custo médio de folha vs produtividade de pipelines entregues e taxa de promoção interna.

2. Piloto Regional & Flexibilidade Híbrida

Testar contratação fora do Sudeste para verificar disponibilidade real de talentos e adotar modelo híbrido flexível calibrado internamente.

MÉTRICA DE ACOMPANHAMENTO

Turnover voluntário em áreas técnicas e tempo de atração de talentos nos polos do Sul e Nordeste.

3. Pilotos de IA Governados com ROI

Migrar de licenças dispersas para um sandbox bancário homologado, medindo ganhos de tempo e qualidade em casos de uso prioritários.

MÉTRICA DE ACOMPANHAMENTO

Retorno financeiro dos pilotos, redução no tempo de esteira de crédito e zero incidentes LGPD.



Regras de Tratamento e Fórmulas Aplicadas

- **Estimativa Salarial:** Ponto médio em faixas fechadas; R\$ 500,00 na faixa inferior aberta (< R\$ 1.000); R\$ 48.000,00 na superior aberta (> R\$ 40.001 com fator 1.2x).
- **Médias Ponderadas:** Para evitar o viés da 'média de médias', toda agregação utiliza:
$$\bar{x}_{\text{pond}} = \frac{\sum (\bar{x}_i \cdot n_i)}{\sum n_i}$$
- **Deduplicação Criptográfica:** Criação de id_registro_tecnico via hash SHA-256 para respostas válidas com token nulo antes do dropDuplicates.
- **Desaninhamento de Tecnologias (Explode):** Divisão de respostas multivaloradas por vírgula e apuração de respondentes únicos distintos por categoria.
- **Taxa de Satisfação Válida:** Denominador estrito sobre respostas booleanas/válidas, excluindo abstenções da base de cálculo.



Registro Formal de Limitações da Pesquisa

- **Amostra Voluntária e Causalidade:** Correlações observadas (ex: trabalho remoto e satisfação) não estabelecem relação de causa e efeito estatístico.
- **Faixa Inconsistente em 2025–2026:** A alternativa 2.h_faixa_salarial contém uma string divergente na fonte, mantida por auditoria (impacto de R\$ 0,21).
- **Looker vs Looker Studio:** Identificação de sobreposição na coluna binária original da pesquisa, corrigida no script de uso real via parsing textual estrito.
- **Uso Pessoal vs Corporativo de IA:** Gestores e não gestores responderam perguntas com universos amostrais e opções de múltipla escolha distintos.

Tema / Pergunta de Diagnóstico	Slide Correspondente	Evidência / Gráfico	Código / Script Fonte
1. Estruturação do mercado brasileiro de Dados	Slides 5 e 6	01_kpis_executivos.png / 02_distribuicao_regional.png	01_estrutura_mercado.csv / Athena Query 1
2. Perfis profissionais mais valorizados	Slide 7	04_remuneracao_perfis.png	03_remuneracao_senioridade.csv / Athena Query 2
3. Cenário de diversidade de gênero nas carreiras	Slide 10	03_diversidade_genero.png	04_diversidade_genero.csv / Athena Query 3
4. Adoção tecnológica de ferramentas e linguagens	Slides 8 e 9	09_uso_real_bi_cloud.png / 05_tecnologias_top5.png	tecnologias_uso_2025_2026.csv / Athena Query 4
5. Índice de adoção de IA e seu impacto	Slides 12 e 13	06_prioridade_ia.png / 07_uso_pessoal_ia.png	06a_prioridade_ia.csv / 06b_uso_pessoal_ia.csv
6. Diferenças entre regiões, níveis e modelos	Slides 6, 7 e 11	08_modelos_trabalho_satisfacao.png	07_modelos_trabalho.csv / Athena Query 6
7. Oportunidades e desafios para investir em Dados e IA	Slides 14, 15 e 16	Matriz Estratégica, Roadmap 90d e 3 Decisões	Síntese Estratégica da Consultoria
PySpark Glue Jobs: glue_job_bronze_to_silver.py / glue_job_silver_to_gold.py	Consultas Athena: scripts/analytics/queries_athena.sql	Quality Gate: scripts/quality/validacao_qualidade.py	Diagrama AWS: diagrams/arquitetura_aws.drawio