

Dados e IA no Brasil: Evidências para a Expansão de uma Instituição Financeira

Diagnóstico Estratégico do Mercado de Trabalho, Remuneração, Tecnologias e Governança de IA com base nas pesquisas State of Data Brasil (2023–2026)

Caso da Instituição Financeira

Suporte a decisões de contratação, remuneração, capacitação técnica, retenção e alocação de capital em iniciativas de Dados & IA.

Arquitetura Medallion AWS

Pipeline em 3 camadas no Amazon S3 (Bronze, Silver, Gold), processamento distribuído com PySpark no AWS Glue e consultas no Amazon Athena.

Amostra Consolidada

14.002 registros históricos (5.293 em 2025–26) auditados sob rígidos critérios

Desafio do Banco: Escalar a Área de Dados e IA com Eficiência de Capital

Três Decisões Centrais que o Estudo Orienta

- 1. **Estratégia de Atração e Remuneração de Talentos:** Identificar onde residem os talentos escassos e calibrar faixas salariais para perfis de alta complexidade (Engenharia de Dados e MLOps) sem inflacionar a folha global.
- 2. **Investimento Tecnológico e Capacitação Interna:** Definir uma stack tecnológica interoperável e desenhar trilhas de upskilling focadas em competências fundamentais transferíveis (SQL, Python, Cloud e Modelagem).
- 3. **Transição de IA Experimental para Pilotos Governados:** Superar o estágio de ferramentas isoladas e criar um modelo corporativo de GenAI com segurança de dados sensíveis (LGPD/Sigilo Bancário) e ROI mensurável.

Foco Executivo: Transformar dados empíricos de mercado em escolhas estratégicas defensáveis para a diretoria do banco.

Tese Central do Diagnóstico de Mercado

O QUE O MERCADO REVELA

A remuneração nominal média estimada avançou +26,4% no período analisado, com aumento de 15% na contratação empresarial de ferramentas de IA (de 6,4% para 42,3%). Persistem forte concentração em grandes bancos (68%), baixa diversidade feminina (22,0%) e disparidade de satisfação em modelos presenciais.

INTERPRETAÇÃO PARA O SETOR FINANCEIRO

O mercado brasileiro de dados amadureceu em custos e expectativas, mas opera com alta volatilidade e dispersão de orçamento em IA sem governança.

DIRETRIZ ESTRATÉGICA PARA O BANCO

Combinar contratação sênior cirúrgica, formação técnica interna de plenos, contratação de talentos especializados em IA e pilotos governados de IA com validação de retorno.

 Composição Amostral por Edição da Pesquisa

5.293

2023–2024

0 dups removidas

5.215

2024–2025

2 dups removidas

3.494

2025–2026


1 dup removida

Etapas de Auditoria	Regra Aplicada	Status
Deduplicação de Chave	Chave (ano, id) com hash SHA-256 para nulos	✔ 0 duplicatas
Estimativa Salarial	Ponto médio em faixas fechadas; 1.2x no topo aberto	✔ Métrica contínua
Completeness Crítica	Gênero (100%), Região (97,2%), Salário (91,7%)	✔ Acima dos limites
Taxa de Satisfação	Denominador estrito sobre respostas válidas	✔ Sem distorção

 Limitações e Ressalvas Metodológicas Essenciais

- Amostra Voluntária de Conveniência:** A pesquisa não constitui um censo por não acompanhar os mesmos indivíduos ano a ano.
- Variação Volumétrica em 2025–2026:** A redução de ~33% no volume de respostas reflete a coleta, e não retração do mercado de trabalho de dados.
- Salários Estimados Nominais:** Os valores salariais são aproximações baseadas na inflação pelo IPCA.
- Faixa Inconsistente Preservada:** Uma inconsistência de digitação na fonte de dados (impacto de R\$ 0,21 na média geral).

Crítério Científico: Variações temporais indicam mudanças na composição da amostra, a ser tratada com cautela estatística.



Arquitetura Oficial — Tech Challenge Fase 3 (Data Lakehouse em 3 Camadas Medallion no Amazon S3 com AWS Glue, PySpark e Athena)

⚙️ Destaques Técnicos da Solução AWS

- **Amazon S3 Data Lake (3 Camadas):**
 - 🟠 **Bronze:** CSVs brutos originais imutáveis.
 - 🟡 **Silver:** Parquet + Snappy particionado por ano, tipo de tecnologia e país.
 - 🟠 **Gold:** 7 Data Marts agregados com contadores ponderados e médias.
- **AWS Glue Jobs (PySpark):**
 - tc3-bronze-to-silver: Leitura com fail-fast, multiline e skip malformed.
 - tc3-silver-to-gold: Explode de tecnologias e países para gerar Data Marts.
- **AWS Glue Data Catalog:** Database centralizado db_state_of_data.
- **Amazon Athena:** Consultas SQL com médias ponderadas e agregações.
- **Complemento Local:** O uso de BI/Cloud (questões 4.g e 4.h) para validar e preservar fidelidade da fonte.

Mercado de dados em cinco indicadores

Última edição e variação acumulada no período

Participação feminina 21,9% 2025-2026 -2.5 p.p. vs. 2023-2024	Concentração no Sudeste 62,1% 2025-2026 +2.2 p.p. vs. 2023-2024	Satisfação no trabalho 69,0% 2025-2026 -3.0 p.p. vs. 2023-2024	Trabalho 100% remoto 36,7% 2025-2026 -4.9 p.p. vs. 2023-2024	Média salarial estimada R\$ 13.329 2025-2026 +26.4% vs. 2023-2024
---	---	--	--	---

Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

A remuneração nominal média estimada cresceu +26,42% (de R\$ 10.536 para R\$ 13.329). O índice de concentração no Sudeste subiu +2,16 p.p. (62,11%), enquanto a representatividade do trabalho remoto recuou -4,92 p.p. (36,66%). A satisfação válida recuou -3,00 p.p. (69,00%) em relação ao período anterior.

2. INTERPRETAÇÃO ESTRATÉGICA


O mercado reflete uma dinâmica de encarecimento nominal da mão de obra, agravada pela concentração regional e sinais de atrito com políticas corporativas de retorno presencial.

3. IMPLICAÇÃO PARA O BANCO

O banco não deve competir exclusivamente por salário no Sudeste, mas sim oferecer programas de formação como alavancas de eficiência.

Distribuição regional dos profissionais

Participação no total de respondentes de cada edição



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

O Sudeste concentra 62,11% dos respondentes na última edição (10,48%), Centro-Oeste (6,55%) e Norte (1,92%). A concentração em todas as edições.

2. INTERPRETAÇÃO ESTRATÉGICA


A excessiva centralização no Sudeste gera uma disputa predatória por custos de atração e rotatividade involuntária.

3. IMPLICAÇÃO PARA O BANCO

Hipótese a testar: Estruturar hubs remotos ou canais de contratação em regiões menos saturadas (PR/SC/RS), Nordeste (PE/CE/BA) e Centro-Oeste para compor o mix regional e reduzir custos operacionais.

Perfis com maior remuneração média

Top 6 em 2025–2026; mínimo de 30 salários válidos



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

Filtro de robustez estatística com mínimo de 30 salários válidos. Salário médio para Engenharia de ML (R\$ 17.689,45), Ciência de Dados (R\$ 16.920,40) e Analytics Engineer (R\$ 15.786,00) estimada. A progressão de Júnior para Sênior no mesmo cargo é de aproximadamente 100%.


2. INTERPRETAÇÃO ESTRATÉGICA

O mercado paga prêmio substancial para quem constrói e sustenta modelos em produção. Cargos de BI e Análise possuem faixas salariais mais baixas, refletindo maior maturidade e estabilidade.

3. IMPLICAÇÃO PARA O BANCO

Não tratar os valores do Top 6 como média geral do mercado. Esses perfis representam a ponta da pirâmide salarial. Para atrair talentos, o banco deve focar em programas de desenvolvimento e retenção para esses níveis avançados, promovendo internamente e oferecendo benefícios diferenciados.

Utilização Tecnológica no Cotidiano dos Profissionais de Dados (2025–2026)
Complemento Analítico Local: Uso Efetivo vs Preferência Declarada



Fonte: State of Data Brasil 2025–2026 (Data Hackers & Bain). Análise complementar local das questões 4.g e 4.e. Não calculado no Athena.

1. EVIDÊNCIA DOS DADOS

Na edição 2025–2026 (questões multiseleção 4.g e 4.e): Power BI lidera com 59,00% (1.241/2.105), seguido por Looker Studio por 15,58% (328/2.105), Tableau por 13,63% (287/2.105), AWS lidera com 48,26% (1.011/2.095), Azure tem 34,84% (730/2.095).

2. INTERPRETAÇÃO ESTRATÉGICA


O ecossistema bancário é predominantemente multicloud e híbrido, com forte presença de AWS e Azure, mas há forte presença combinada de Azure e GCP.

3. IMPLICAÇÃO PARA O BANCO

Garantir arquitetura corporativa interoperável e governança centralizada é fundamental para otimizar custos e segurança. Capacitar equipes em fundamentos multicloud.

Tecnologias com maior adoção em 2025-2026

Top 5 por categoria; Linguagens permitem múltiplas respostas



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

Em preferências técnicas declaradas: Python (92,07%) e SQL (84,2%) lideram. (n=2.094 válidas em 2025–2026). Em preferência de BI: Power BI (50,5%), Tableau (9,8%), Looker (6,4%), Metabase (4,1%) e Amazon QuickSight (3,0%). Cloud: AWS (31,74%), GCP (22,55%) e Azure (20,13%).

2. INTERPRETAÇÃO ESTRATÉGICA


SQL e Python são as competências universais de maior liquidez no mercado. O domínio de ferramentas de BI e a escolha de nuvens (AWS, GCP, Azure) refletem a maturação da infraestrutura de Analytics e Data Science.

3. IMPLICAÇÃO PARA O BANCO

Estruturar trilhas internas de upskilling baseadas em SQL avançada e Python, com foco em automação/análise e governança de dados na nuvem, reduzindo custos e aumentando a eficiência operacional.


Participação feminina

Percentual sobre todos os respondentes



Diferença salarial de gênero

Quanto a média feminina está abaixo da média masculina



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

A participação feminina recuou para 21,95% na amostra de 2023. A diferença salarial média bruta declarada é de ~19,4% (Homens: R\$ 13.944, Mulheres: R\$ 11.444).

2. INTERPRETAÇÃO ESTRATÉGICA


Ressalva Metodológica: Trata-se de diferença bruta, não ajustada por experiência. Ela reflete a sub-representação feminina em posições de maior impacto econômico.

3. IMPLICAÇÃO PARA O BANCO

Implementar programas de mentoria e formação afirmativa para mulheres. Conduzir auditorias internas de equidade salarial em funções idênticas.

Distribuição dos modelos


Participação em 2025–2026



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

Satisfação por modelo

Sobre respostas válidas em 2025–2026



1. EVIDÊNCIA DOS DADOS

Em 2025–2026 (respostas válidas): 100% Remoto (74,80%) e Híbrido Flexível (75,00%) — superior ao 100% Presencial (52,10%) — uma diferença de mais de 20 pontos percentuais.

2. INTERPRETAÇÃO ESTRATÉGICA


Profissionais de alta performance em tecnologia percebem flexibilidade no trabalho como um dos principais fatores de qualidade de vida e produtividade.

3. IMPLICAÇÃO PARA O BANCO

Hipótese de retenção: Adotar o modelo Híbrido Flexível com 100% de adoção como padrão, validando o impacto com dados internos de turnover e engajamento.

Prioridade de IA nas empresas

Distribuição entre respondentes válidos da pergunta



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

Entre os gestores respondentes (n=652 em 2025–2026), 60,58% (39,42% prioridade relevante, 21,16% principal prioridade da empresa).

2. INTERPRETAÇÃO ESTRATÉGICA


Ressalva: O indicador mede a percepção dos gestores participantes e reflete forte pressão executiva por adoção e alocação de orçamento.

3. IMPLICAÇÃO PARA O BANCO

Canalizar o apetite executivo para casos de uso estruturantes (e.g., automação de compliance), evitando dispersão em iniciativas seletivas.

Uso pessoal de soluções de IA

Pergunta multiseleção; percentuais não precisam somar 100%



Fonte: State of Data Brasil | Processamento próprio em AWS Glue/Athena

1. EVIDÊNCIA DOS DADOS

Entre não gestores (n=2.105 em 2025–2026): 42,33% utilizam ferramentas de IA voltadas para o trabalho em 2023–2024). 29,83% usam ferramentas de IA voltadas para o trabalho

2. INTERPRETAÇÃO ESTRATÉGICA

O financiamento corporativo comprova compra institucional de IA, o que atesta governança de dados sensíveis nem mensuração de produtividade

3. IMPLICAÇÃO PARA O BANCO

Criar um ambiente corporativo protegido (sandbox seguro com IA) para aumentar a produtividade em pilotos controlados de desenvolvimento de soluções

Matriz de Decisões Estratégicas para a Instituição Financeira

Pilar Estratégico	Evidência dos Dados	Risco ou Oportunidade	Decisão Proposta
1. Contratação	Sêniores em Engenharia/ML recebem até R\$ 17.689; concentração de 62% no Sudeste.	Disputa predatória inflaciona custos locais e alonga tempo de contratação.	Contratar sêniores cirurgicamente e abrir vagas distribuídas no Nordeste.
2. Capacitação	Python (92%) e SQL (84%) lideram com folga as preferências de linguagens.	Treinamentos dispersos em ferramentas de nicho geram baixo retorno.	Criar academia interna de dados focada em SQL avançado, Python e arquitetura cloud.
3. Retenção	Modelos flexíveis superam o presencial em mais de 20 p.p. na satisfação válida.	Imposição 100% presencial arrisca perda dos profissionais mais produtivos.	Consolidar Híbrido Flexível (1-2 dias presenciais para ritos de alinhamento).
4. Diversidade	Participação feminina de 22,0% e diferença salarial média bruta de 19,4%.	Homogeneidade limita inovação e prejudica a imagem institucional.	Metas de recrutamento afirmativo e aceleração de lideranças talentosas e femininas.
5. Inteligência Artificial	42,3% usam IA paga pela empresa; 60,6% dos gestores veem IA como prioridade.	Dispersão de capital e riscos de segurança de dados bancários (LGPD).	Implantar sandbox corporativo seguro e homologar 3 casos de uso de IA para redução de crédito/fraude.

Plano de Ação Proposto: Cronograma de 0 a 90 Dias

1 0 a 30 Dias: Diagnóstico & Alinhamento

- **Mapeamento de Competências:** Levantar inventário interno de proficiência em SQL, Python, Cloud e Modelagem.
- **Revisão do Funil de Talentos:** Mapear vagas abertas e aprovar política de contratação remota para Sul/Nordeste.
- **Seleção de Casos de Uso de IA:** Selecionar 2 a 3 pilotos de GenAI (ex: esteira de crédito e copiloto de código).

Entrega: Matriz de gaps técnicos e termo de abertura dos pilotos de IA.

2 31 a 60 Dias: Estruturação & Pilotos

- **Lançamento da Academia de Dados:** Iniciar trilhas internas de SQL e Engenharia de Dados na AWS.
- **Sandbox Seguro de GenAI:** Homologar ambiente protegido com mascaramento de dados (LGPD e sigilo bancário).
- **Política Híbrida Flexível:** Formalizar diretriz de 1-2 dias presenciais focados em ritos colaborativos.

Entrega: Pilotos de IA em execução e 1ª turma de capacitação iniciada.

3 61 a 90 Dias: Mensuração

- **Avaliação de ROI dos Pilotos:** Medir impacto de modelos de IA frente ao baseline.
- **Auditoria de Equidade Salarial:** Realizar análise de gênero para cargos iguais.
- **Escala do Pipeline Regional:** Implementar em novos contratados fora do Sudeste.

Entrega: Relatório executivo de resultados em 3 meses.

1

Capacidades Críticas & Engenharia

Contratar sêniores cirurgicamente para arquitetura e liderança de dados, enquanto capacita a base interna em SQL avançado e Python.

MÉTRICA DE ACOMPANHAMENTO

Custo médio de folha vs produtividade de pipelines entregues e taxa de promoção interna.

2

Atração Distribuída & Flexibilidade

Expandir o recrutamento para fora do eixo Rio-SP e consolidar o modelo Híbrido Flexível para blindar a equipe contra o turnover.

MÉTRICA DE ACOMPANHAMENTO

Turnover voluntário em áreas técnicas (< 8% ao ano) e tempo de atração de talentos.

3

Pilotos de IA Governados

Migrar de licenças dispersas para uma plataforma unificada, visando ganhos de tempo e qualidade em operações críticas.

MÉTRICA DE ACOMPANHAMENTO

Retorno financeiro dos pilotos, redução de incidentes LGPD.



Regras de Tratamento e Fórmulas Aplicadas

- **Estimativa Salarial:** Ponto médio em faixas fechadas; R\$ 500,00 na faixa inferior aberta (< R\$ 1.000); R\$ 48.000,00 na superior aberta (> R\$ 40.001 com fator 1.2x).
- **Médias Ponderadas:** Para evitar o viés da 'média de médias', toda agregação utiliza:
$$\bar{x}_{i \cdot \text{pond}} = \frac{\sum (\bar{x}_i \cdot n_i)}{\sum n_i}$$
- **Deduplicação Criptográfica:** Criação de id_registro_tecnico via hash SHA-256 para respostas válidas com token nulo antes do dropDuplicates.
- **Desaninhamento de Tecnologias (Explode):** Divisão de respostas multivaloradas por vírgula e apuração de respondentes únicos distintos por categoria.
- **Taxa de Satisfação Válida:** Denominador estrito sobre respostas booleanas/válidas, excluindo abstenções da base de cálculo.



Registro Formal de Limitações da Pesquisa

- **Amostra Voluntária e Causalidade:** Correlações observadas (ex: trabalho remoto vs produtividade) não implicam causalidade direta sem controle estatístico rigoroso para causa e efeito estatístico.
- **Faixa Inconsistente em 2025–2026:** A alternativa 2.h_faixa_salarial contém inconsistências identificadas por auditoria (impacto de R\$ 0,21).
- **Looker vs Looker Studio:** Identificação de sobreposição na coluna binária de acesso por dispositivo móvel real via parsing textual estrito.
- **Uso Pessoal vs Corporativo de IA:** Gestores e não gestores responderam por diferentes canais de pesquisa de múltipla escolha distintos.

Pergunta Obrigatória do Enunciado	Slide Correspondente	Evidência / Gráfico	Código / Script Fornecido
1. Como está estruturado o mercado brasileiro de Dados?	Slides 5 e 6	01_kpis_executivos.png / 02_distribuicao_regional.png	01_estrutura_mercado.py
2. Quais perfis profissionais são mais valorizados?	Slide 7	04_remuneracao_perfis.png	03_remuneracao_perfis.py
3. Qual o cenário de diversidade de gênero nas carreiras?	Slide 10	03_diversidade_genero.png	04_diversidade_genero.py
4. Quais tecnologias apresentam maior adoção?	Slides 8 e 9	09_uso_real_bi_cloud.png / 05_tecnologias_top5.png	05_tecnologias_uso.py
5. Qual o índice de adoção de IA e seu impacto?	Slides 12 e 13	06_prioridade_ia.png / 07_uso_pessoal_ia.png	06a_prioridade_ia.py
6. Existem diferenças entre regiões, níveis e modelos?	Slides 6, 7 e 11	08_modelos_trabalho_satisfacao.png	07_modelos_trabalho.py
7. Quais oportunidades e desafios para investir em Dados e IA?	Slides 14, 15 e 16	Matriz Estratégica, Roadmap 90d e 3 Decisões	Síntese Estratégica
 PySpark Glue Jobs: glue_job_bronze_to_silver.py / glue_job_silver_to_gold.py  Consultas Athena: scripts/analytics/queries_athena.sql  Quality Gate: scripts/quality/validacao_qualidade.py  Diagrama AWS: diagrams/infrastructure_aws.png			